

Микробиота диких и лабораторных мышей: анализ ампликонов V4 16S рРНК в QIIME 2

Коротков Антон

21 сентября

О данных

Данные взяты из работы Rosshart et al. (Cell, 2017). Авторы пересаживали стерильным (germ-free) мышам C57BL/6 кишечную микробиоту либо обычных лабораторных мышей, либо диких мышей, пойманных в природе. Потом они сравнивали, как такие мыши переносят грипп и колоректальный рак. В нашем наборе 29 образцов в четырёх группах:

- L — лабораторные мыши, доноры «лабораторной» микробиоты;
- W — дикие мыши, доноры «дикой» микробиоты;
- LR — бывшие germ-free мыши после пересадки лабораторной микробиоты (LabR в статье);
- WR — бывшие germ-free мыши после пересадки дикой микробиоты (WildR).

Секвенировали участок V4 гена 16S рРНК (праймеры 515F/806R) на Illumina MiSeq с парными прочтениями 2×250 нт.

Главный вопрос для нашего анализа: насколько точно каждое сообщество переносится в нового хозяина и чем дикая микробиота отличается от лабораторной.

Обработка шла в QIIME 2 версии 2024.10, запущенном из Singularity-образа quay.io/qiime2/amplicon:2024.10 (conda-канал QIIME 2 с кластера недоступен).

Качество сырых прочтений

```
fastqc -t 20 -o fastqc <all R1 and R2 files from the manifest>
multiqc -f -n mice_multiqc_report -o multiqc fastqc
```




Рис. 1: Среднее качество по позициям для всех 58 файлов (MultiQC).

Что можно сказать о прочтениях. Профиль качества типичный для MiSeq 2 × 250. Начало прочтений очень качественное, к концу качество падает. У прямых прочтений средний Phred-балл держится выше 30 примерно до позиции 225, у обратных только до 165 (медианы по файлам). То, что R2 хуже R1, — известная особенность Illumina: второе прочтение идёт после регенерации кластеров, и ошибок фазирования к его концу накапливается больше.

Красными у всех файлов оказываются одни и те же модули: Per base sequence quality, Per base sequence content, Sequence Duplication Levels, Overrepresented sequences. Для ампликонных данных это нормально: все прочтения начинаются в одной точке гена 16S, одинаковые последовательности повторяются тысячи раз, а самые частые из них — это просто самые многочисленные бактерии. На выбросы по отдельным образцам MultiQC не указывает.

Импорт и статистика сырых прочтений

```
qiime tools import \
  --type 'SampleData[PairedEndSequencesWithQuality]' \
  --input-path input/metadata_for_input.fixed.tsv \
  --output-path qza/mice_reads.qza \
  --input-format PairedEndFastqManifestPhred33V2
qiime demux summarize --i-data qza/mice_reads.qza --o-visualization qzv/mice_reads.qzv
```

Манифест из задания ссылался на пути другого сервера. Скрипт перед импортом находит каждый fastq-файл по имени и переписывает манифест.




Рис. 2: Качество прямых (слева) и обратных (справа) прочтений.

Всего 134 672 пар прочтений: от 2 138 до 6 394 на образец, медиана 4 918. Разброс глубины всего 3,0-кратный, для ампликонного секвенирования это ровно.

DADA2: как выбраны параметры

Обрезка слева. Сначала надо понять, есть ли в прочтениях праймеры. Скрипт ищет 515F в начале R1 и 806R в начале R2 (регулярное выражение с учётом вырожденных позиций). 515F нашёлся в 0,0 % прочтений R1, 806R — в 0,0 % прочтений R2. Праймеров в прочтениях нет, и R1 начинается сразу с последовательности V4. Либо их срезали при подготовке данных, либо секвенирующий праймер садился прямо на ПЦР-праймер, и его последовательность просто не читалась. Поэтому `trim-left-f = 0` и `trim-left-r = 0`.

```
zcat <R1.fq.gz> | head -n 8000 \
  | awk 'NR%4==2 && match($0, /GTGCCAGC[AC]GCCGCGGTAA/) {n++} END {print n+0, "of", NR/4}'
```

Обрезка справа. R1 обрезан до 240 нт, R2 — до 160 нт, по графикам качества выше: отображаются хвосты, на которых качество уже заметно просело. Резать можно смело, потому что ампликон короткий. Без праймеров V4 занимает около 253 нт. После обрезки R1 покрывает первые 240 нт, R2 — последние 160 нт, и перекрытие составляет $240 + 160 - 253 = 147$ нт. DADA2 для склейки нужно минимум 12 нт без несовпадений, так что запас огромный, и граница обрезки выбирается только по качеству.

```
qiime dada2 denoise-paired \
  --i-demultiplexed-seqs qza/mice_reads.qza \
  --p-trim-left-f <TrimF> --p-trim-left-r <TrimR> \
  --p-trunc-len-f <TruncF> --p-trunc-len-r <TruncR> \
  --p-n-threads 20 \
  --o-table qza/mice_ASV_table.qza \
  --o-representative-sequences qza/mice_rep_seq.qza \
```

```
--o-denoising-stats qza/mice_reads.dada2.stats.qza
```

DADA2: сколько прочтений осталось

Этап	Ридов всего	% от входа	Медиана на образец
на входе	134 672	100,0	4 918
после фильтра по качеству	107 055	79,5	3 985
после денойзинга	101 478	75,4	3 789
после склейки R1+R2	88 113	65,4	3 238
без химер	87 011	64,6	3 100

Таблица 1: Прочтения на этапах DADA2 (сумма по всем образцам).

До конца дошло 87 011 пар, то есть 64,6 % исходных. Фильтр по качеству отсеивает 20,5 процентного пункта (прочтения, у которых после обрезки ожидаемое число ошибок больше двух). Денойзинг забирает 4,1, склейка пар — 9,9. Химер почти нет: 0,8 п.п.

Группа	<i>n</i>	Медиана, %	Размах, %
L	8	60,0	56,3–63,1
LR	7	72,0	66,9–74,4
W	7	57,1	53,3–66,8
WR	7	66,0	64,1–71,2

Таблица 2: Доля прочтений, прошедших все этапы, по группам.

По образцам доля сохранённых прочтений от 53,3 % (W5) до 74,4 % (LR1). У диких мышей она ниже (медиана 57,1 % против 60,0 % у лабораторных). В разнообразном сообществе больше редких вариантов, и DADA2 чаще не может отличить их от ошибок секвенирования

Таблица ASV

```
qiime feature-table summarize --i-table qza/mice_ASV_table.qza \
  --m-sample-metadata-file input/metadata.tsv --o-visualization qzv/mice_ASV_table.qzv
qiime feature-table tabulate-seqs --i-data qza/mice_rep_seq.qza --o-visualization qzv/mice_rep_seq.qzv
```




Рис. 3: Распределение числа прочтений по образцам

В таблице 480 ASV и 87 011 прочтений. Глубина образцов от 1 198 (W1) до 4 431 (LR2), медиана 3 100. По ASV распределение сильно скошено. Медианный ASV встречается 50 раз, самый частый — 4 843; десять самых частых ASV дают 29,7 % всех прочтений. 39,8 % вариантов встречаются только у одной мыши.

На семинаре была фильтрация образцов по глубине (`feature-table filter-samples --p-min-frequency 14000`). На этих данных порог 14 000 бессмыслен: самый глубокий образец содержит 4 431 прочтений, и фильтр выкинул бы всех мышей. Поэтому дальше используется полная таблица, а неравномерность глубины учитывается разрежением.

Таксономия

```
qiime feature-classifier classify-sklearn \
  --i-classifier 2022.10.backbone.v4.nb.sklearn-1.4.2.qza \
  --i-reads qza/mice_rep_seq.qza --p-n-jobs 8 \
  --o-classification qza/mice_taxonomy.qza
qiime taxa barplot --i-table qza/mice_ASV_table.qza --i-taxonomy qza/mice_taxonomy.qza \
  --m-metadata-file input/metadata.tsv --o-visualization qzv/mice_taxonomy_barplot.qzv
```

Классификатор — наивный байесовский, обучен на участке V4 последовательностей GreenGenes2. Для каждого ASV он считает вероятности таксонов по частотам 7-меров и присваивает самый глубокий уровень, на котором уверенность не ниже 0,7. Если на уровне рода уверенности не хватает, ASV остаётся определённым только до семейства или порядка.




Рис. 4: Состав на уровне типов (Level 2), образцы сгруппированы по группам.

Тип	L	LR	W	WR
Firmicutes_A	72,8	82,7	30,3	55,3
Bacteroidota	14,6	11,1	25,7	24,0
Campylobacterota	0,0	0,0	23,5	11,7
Desulfobacterota_I	0,0	0,0	8,3	3,8
Deferribacterota	6,8	3,0	0,5	2,8
Proteobacteria	0,1	0,0	5,8	0,4
Firmicutes_D	3,4	2,0	4,9	1,0

Таблица 3: Средняя доля основных типов по группам, %.

Лабораторные мыши почти целиком состоят из Firmicutes_A: 72,8% у L и 82,7% у LR. У диких мышей Firmicutes_A всего 30,3%. Зато у них есть целые типы, которых у лабораторных нет совсем: Campylobacterota (23,5%), Proteobacteria (5,8%), Desulfobacterota_I (8,3%).

Группа WR интереснее всего. Мыши, получившие дикую микробиоту, унаследовали от доноров Campylobacterota (11,7%), которых нет ни у L, ни у LR. Но пропорции другие: Firmicutes_A у них 55,3%, заметно больше, чем у доноров, а Proteobacteria почти исчезли (0,4%). То есть набор линий переносится, а соотношение между ними новый хозяин перестраивает под себя. Скорее всего, дело в лабораторном корме и условиях вивария.




Рис. 5: Состав на уровне родов (Level 6).

Род	L	LR	W	WR
Lachnospiraceae (н/о)	24,0	14,4	1,4	7,6
<i>Helicobacter_D</i>	0,0	0,0	13,7	11,4
<i>COE1</i>	9,0	10,9	5,0	8,5
<i>Helicobacter_C</i>	0,0	0,0	9,8	0,3
<i>Parabacteroides_B</i>	9,5	4,9	0,6	1,9
<i>Mailhella</i>	0,0	0,0	8,1	3,4
<i>Bacteroides_H</i>	0,0	0,0	8,1	1,9
<i>Mucispirillum</i>	6,8	3,0	0,4	2,8
<i>Alistipes_A</i>	5,2	6,2	1,8	4,1
<i>Odoribacter</i>	0,0	0,0	0,3	5,8

Таблица 4: Десять самых частых родов, средняя доля по группам, %. «н/о» — род не определён, указан ближайший известный ранг.

Роды, которые у диких мышей занимают больше 1 %, а у WR почти не встречаются (меньше 0,05 %): *Ligilactobacillus*, *Coprocola*, *Prevotella*. Эти линии при пересадке не прижились.

Филогенетическое дерево

```
qiime phylogeny align-to-tree-mafft-fasttree --i-sequences qza/mice_rep_seq.qza --p-n-threads 20 \
--o-alignment qza/aligned_mice_rep_seq.qza --o-masked-alignment qza/masked_aligned_mice_rep_seq.qza \
--o-tree qza/mice_unrooted_tree.qza --o-rooted-tree qza/mice_rooted_tree.qza
```

MAFFT выравнивает последовательности ASV, из выравнивания убираются слишком изменчивые колонки. FastTree строит дерево, и его укореняют по середине самого длинного пути




Рис. 6: Филогенетическое дерево 480 ASV.

Больше всего ASV в Firmicutes_A (336), дальше идут Bacteroidota (81) и Firmicutes_D (28). ASV одного типа собираются в свои клады. Это хорошая проверка: дерево строилось только по выравниванию, классификатор — только по базе, а результаты согласуются.

Альфа-разнообразие

```
qiime diversity core-metrics-phylogenetic \
  --i-phylogeny qza/mice_rooted_tree.qza --i-table qza/mice_ASV_table.qza \
  --p-sampling-depth <depth> --m-metadata-file input/metadata.tsv \
  --output-dir mice_core_metrics_results
qiime diversity alpha-group-significance \
  --i-alpha-diversity mice_core_metrics_results/shannon_vector.qza \
  --m-metadata-file input/metadata.tsv \
  --o-visualization mice_core_metrics_results/mice_shannon_significance.qzv
```

Прежде чем сравнивать разнообразие, все образцы разрежены до одной глубины, 1 198 прочтений. Без этого образец, прочитанный глубже, выглядел бы богаче только потому, что в нём успели попасться редкие ASV. Глубина выбрана по самому маленькому образцу (W1), так что в анализе остаются все 29 мышей из 29.

Группа	Shannon	Pielou	ASV	Faith PD
L	5,05	0,87	58	5,84
LR	5,67	0,89	82	6,65
W	4,42	0,82	51	5,77
WR	5,66	0,87	91	8,11

Таблица 5: Медианы метрик альфа-разнообразия по группам: индекс Шеннона, равномерность Пилу, число ASV и филогенетическое разнообразие Фейта.




Рис. 7: Индекс Шеннона по группам.

Различия между группами значимы: Краскел–Уоллис по индексу Шеннона даёт $H = 20,83$, $p = 1,1 \cdot 10^{-4}$.

Группа 1	Группа 2	H	p	q
L	LR	10,50	0,001	0,005
L	W	4,34	0,037	0,045
L	WR	8,37	0,004	0,006
LR	W	9,80	0,002	0,005
LR	WR	0,10	0,749	0,749
W	WR	9,02	0,003	0,005

Таблица 6: Попарные сравнения по индексу Шеннона (Краскел–Уоллис, q — поправка Бенджамини–Хохберга).

Интереснее всего пара LR–WR: $q = 0,749$. Реципиенты двух разных микробиот по Шеннону неразличимы (медианы 5,67 и 5,66). У доноров картина другая: у диких мышей индекс ниже (4,42 против 5,05).

На первый взгляд странно, что дикие мыши оказываются «беднее» лабораторных. Разгадка в равномерности. По Пиелу у W медиана 0,82, у L — 0,87: сообщество диких мышей неравномерное, в нём есть сильные доминанты (Campylobacterota и Bacteroidota, см. таблицу типов), и Шеннон это наказывает. Филогенетическое разнообразие Фейта при этом у W 5,77 против 5,84 у L: оно считает не доли, а длину ветвей дерева, и у диких мышей на него работают целые типы, которых нет у лабораторных.




Рис. 8: Равномерность Пиелу по группам.




Рис. 9: Филогенетическое разнообразие Фейта по группам.

Бета-разнообразие

```
qiime diversity beta-group-significance \
  --i-distance-matrix mice_core_metrics_results/weighted_unifrac_distance_matrix.qza \
  --m-metadata-file input/metadata.tsv --m-metadata-column group \
  --p-method permanova --p-pairwise \
  --o-visualization qzv/mice_weighted_unifrac_group_significance.qzv
```




Рис. 10: PCoA по weighted UniFrac, цвет — группа.

Первая ось объясняет 59,24 % изменчивости, вторая 13,06 %, третья 6,43 %. Первая ось разделяет лабораторный и дикий профили: L и LR с одной стороны, W и WR с другой. По второй оси WR отходит от своих доноров. Лабораторные группы лежат плотными облаками, а дикие мыши разбросаны широко. Это понятно: у каждой дикой мыши своя история питания и окружения, а лабораторные живут в одинаковых условиях.

PERMANOVA по группам: $\text{pseudo-}F = 19,56$, $p = 0,001$ (999 перестановок).

Группа 1	Группа 2	$\text{pseudo-}F$	p	q
L	LR	6,50	0,001	0,001
W	WR	9,73	0,001	0,001
LR	W	23,08	0,001	0,001
L	W	24,31	0,001	0,001
LR	WR	26,57	0,001	0,001
L	WR	29,02	0,001	0,001

Таблица 7: Попарная PERMANOVA (weighted UniFrac), пары отсортированы по $\text{pseudo-}F$.

Ближе всего друг к другу L и LR ($\text{pseudo-}F = 6,50$): лабораторная микробиота переносится в стерильную мышь почти без искажений. Дикая переносится хуже, W и WR различаются сильнее (9,73). Сильнее всех различаются L и WR (29,02): две лабораторные линии мышей с разной микробиотой расходятся дальше, чем доноры между собой.

	L	LR	W	WR
L	0,10	0,13	0,34	0,23
LR	0,13	0,09	0,35	0,23
W	0,34	0,35	0,22	0,27
WR	0,23	0,23	0,27	0,11

Таблица 8: Среднее расстояние weighted UniFrac между группами; на диагонали — между мышами внутри группы.

Средние расстояния говорят то же самое. Внутри L мыши отстоят друг от друга в среднем на 0,10, от LR — на 0,13, почти столько же. Внутри W расстояние 0,22, это самая «рыхлая» группа.

Такой разброс внутри W нужно учитывать, потому что PERMANOVA чувствительна не только к сдвигу центров групп, но и к разнице в их разбросе. Проверка PERMDISP даёт $F = 19,05$, $p = 0,001$. Значит, часть сигнала PERMANOVA по диким мышам объясняется именно большим разбросом, а не только сдвигом. Разделение лабораторных и диких групп на PCoA при этом видно и без всякой статистики.




Рис. 11: Распределения расстояний weighted UniFrac от каждой группы до остальных.




Рис. 12: PCoA по unweighted UniFrac, цвет — группа.

Unweighted UniFrac учитывает только, какие ветви дерева есть в образце, без численностей. Первые оси здесь объясняют меньше (43,74 и 14,10 %), но разделение лабораторных и диких групп остаётся. Значит, группы различаются не только пропорциями, но и самим набором линий. WR по набору ближе к W, потому что унаследовал «дикие» типы, а по пропорциям (weighted) сдвинут в сторону, потому что хозяин перестроил соотношения.

Итог

Лабораторная микробиота переносится в стерильную мышь почти без потерь: L и LR почти совпадают и по составу, и на PCoA. Дикая переносится частично. Набор линий (Campylobacterota, Desulfobacterota_I) наследуется, но пропорции меняются, Proteobacteria почти исчезают, а Firmicutes_A разрастаются. Альфа-разнообразие реципиентов одинаковое и не показывает, чью микробиоту пересадили. Различить группы позволяют состав и бета-разнообразие, причём и по численностям (weighted UniFrac), и по набору линий (unweighted).