

ДЗ 2. Foxd3 bioChIP-seq на четырёх стадиях от гастрюляции до миграции нервного гребня

Коротков Антон

27 сентября

1 Постановка

На семинаре весь путь от ВАР до пиков был пройден для 14ss, а для 5–6ss был готовый разбор. Здесь то же самое делается для двух оставшихся стадий, после чего все четыре сводятся вместе:

Стадия	Что происходит с нервным гребнем	Обозначение ниже
75 % epiboly	гастрюляция	75ep
1–2 somite stage	индукция	1-2ss
5–6 somite stage	спецификация	5-6ss
14 somite stage	миграция	14ss

Главный вопрос: как меняется геномный ландшафт связывания Foxd3 от гастрюляции к миграции и какую часть различий между стадиями можно считать биологией, а какую не отличить от разницы в качестве самих ChIP-экспериментов.

Из-за второй половины вопроса одного семинарского пайплайна тут мало: если сравнивать только списки пиков, любая разница в эффективности ChIP или глубине секвенирования будет выглядеть как «изменение связывания». Поэтому в анализ добавлено то, что оценивают сами эксперименты: *fingerprint* и *JSD*, доля ридов в тех же пиках, пересчёт пиков при одинаковой глубине и сравнение сигнала на общем наборе регионов, а не только пересечение списков.

2 Данные и обработка

Таблица 1: Откуда данные по каждой стадии и глубина библиотек (число записей в ВАР)

Стадия	Источник	ChIP	Input
75ep	посчитано в пайплайне	23 863 894	39 931 858
1-2ss	посчитано в пайплайне	12 816 614	33 460 348
5-6ss	готовые файлы	18 853 396	н/д
14ss	посчитано в пайплайне	41 553 880	27 794 668

Таблица 2: Параметры, общие для всех стадий

Шаг	Параметры	Почему так
bamCoverage	CPM, бин 10 п.н.	треки разной глубины сравнимы; форма пика видна в IGV
bigwigCompare	log2, pseudocount 1	наглядно, где ChIP выше Input; количественно не используется (псевдосчёт сжимает отношения)
MACS3	BAMPE, $g = 1,36 \cdot 10^9$, $q < 0,01$	фрагменты берутся из пар; одинаковый порог FDR для всех стадий
computeMatrix	± 2 kb от summit, бин 20 п.н.	хватает, чтобы увидеть и пик, и фон вокруг
plotFingerprint	500 000 бинов по 500 п.н.	метрика качества, не зависящая от peak calling

3 Две новые стадии: 75ep и 1-2ss

Таблица 3: Основные числа по 75ep и 1-2ss (для сравнения — 14ss с семинара)

	75ep	1-2ss	14ss
ChIP, записей	23 863 894	12 816 614	41 553 880
Input, записей	39 931 858	33 460 348	27 794 668
ChIP / Input	0,60	0,38	1,50
Properly paired, ChIP	100,00 %	100,00 %	100,00 %
Дубликаты ChIP / Input (MACS3)	0 % / 0 %	0 % / 0 %	0 % / 0 %
Длина фрагмента d , п.н.	207	210	205
Пиков ($q < 0,01$)	36	40	170
Медианная ширина, п.н.	291	260	310
Медианный FE	5,8	6,1	3,3
FRiP ChIP	0,0200 %	0,0100 %	0,160 %
FRiP Input в тех же пиках	0,0100 %	0 %	0,0900 %
ChIP / Input в пиках	$2,0 \times$	н/д	$1,8 \times$
JSD (ChIP vs Input)	0,019	0,036	0,016
Центр/края профиля, ChIP	$7,2 \times$	$8,6 \times$	$2,7 \times$
Центр/края профиля, Input	$3,2 \times$	$1,7 \times$	$2,4 \times$
Пиков, где Input $\geq 0,5$ ChIP	12	2	96

QC. По `flagstat` обе новые стадии выглядят так же, как 14ss: всё картировано, все пары правильные, дубликаты не помечены (их долю снова оценивает MACS3, см. таблицу). Разница в другом: у обеих ранних стадий Input глубже ChIP (отношение ChIP/Input 0,60 и 0,38), а сами ChIP-библиотеки мельче, чем у 14ss (23 863 894 и 12 816 614 против 41 553 880).

Пики. На 75ep найдено 36 пиков, на 1-2ss — 40. Самые значимые:

- 75ep: `foxd3_75ep_peak_2`, NC_007113.7:33 276 014-33 276 551 (NC_007113.7 (хр. 2)), FE = 21,70, $-\log_{10} q = 100,05$, то есть $q \approx 8,9 \cdot 10^{-101}$;
- 1-2ss: `foxd3_1-2ss_peak_3`, NC_007113.7:33 276 062-33 276 596 (NC_007113.7 (хр. 2)), FE = 21,23, $-\log_{10} q = 56,18$, $q \approx 6,6 \cdot 10^{-57}$.

Самые значимые пики 75ep и 1-2ss приходятся на один и тот же участок (NC_007113.7 (хр. 2) summit 33 276 264 и 33 276 279), расхождение summit 15 п.н. В объединённом наборе этот регион найден на 4 стадиях из 4 (75ep+1-2ss+5-6ss+14ss), то есть это не случайный выброс одной библиотеки..

Таблица 4: Пять самых значимых пиков 75ер (сверху) и 1-2ss (снизу); ближайший ген — по `genes.bed`, просто как ориентир

Пик	Координаты	FE	$-\log_{10} q$	Ближайший ген
foxd3_75ep_peak_2	NC_007113.7:33276014–33276551	21,7	100,0	<i>klf17</i> (50 kb)
foxd3_75ep_peak_7	NC_007115.7:24985705–24986018	17,6	91,3	<i>LOC137491399</i> (28 kb)
foxd3_75ep_peak_10	NC_007117.7:32206595–32206920	6,6	59,1	<i>LOC137495883</i> (59 kb)
foxd3_75ep_peak_3	NC_007113.7:55663601–55663948	11,6	53,8	<i>LOC137487493</i>
foxd3_75ep_peak_23	NC_007127.7:7514954–7515335	11,3	46,9	<i>LOC137487875</i> (37 kb)
foxd3_1-2ss_peak_3	NC_007113.7:33276062–33276596	21,2	56,2	<i>klf17</i> (50 kb)
foxd3_1-2ss_peak_26	NC_007127.7:7514971–7515391	18,4	43,2	<i>LOC137487875</i> (37 kb)
foxd3_1-2ss_peak_11	NC_007117.7:32206548–32206898	8,4	30,7	<i>LOC137495883</i> (59 kb)
foxd3_1-2ss_peak_6	NC_007115.7:24985734–24985998	11,0	19,7	<i>LOC137491399</i> (28 kb)
foxd3_1-2ss_peak_31	NC_007132.7:43198481–43198771	8,9	16,4	<i>aff4</i>

FRiP. Считается так же, как на семинаре:

$$\text{FRiP}_{75ep} = \frac{4\,101}{23\,863\,894} \approx 0,0200\%, \quad \text{FRiP}_{1-2ss} = \frac{1\,799}{12\,816\,614} \approx 0,0100\%.$$

Это в 8,0–16 раз ниже, чем у 14ss (0,160%). До ориентира ENCODE в 1% тут далеко, но сравнивать с ним напрямую не очень осмысленно: когда пиков несколько десятков, они физически не могут собрать заметную долю библиотеки. Информативнее отношение ChIP к Input в тех же пиках, оно от числа пиков зависит слабее: у 75ер 2,0 ×, у 1-2ss н/д, у 14ss 1,8 ×.




Рис. 1: Средний сигнал ChIP и Input вокруг summit: 75ер (слева) и 1-2ss (справа)




Рис. 2: Сигнал по каждому пику: 75ер (36 пиков, слева) и 1-2ss (40, справа)

Профили и heatmap. По тем же матрицам посчитано отношение сигнала в центре окна (± 200 п.н.) к краям. На 75ер у ChIP $7,2 \times$, у Input $3,2 \times$. Таких пиков 12 из 36 (33%), это заметная доля. В этих местах фон и так высокий, и повышенное покрытие там может быть не связыванием Foxd3, а свойством самого участка: повторы, схлопнутые при сборке копии, сильно открытый хроматин, который лучше фрагментируется. На heatmap они как раз собираются в верхних строках, где Input тоже яркий. На 1-2ss у ChIP $8,6 \times$, у Input $1,7 \times$. Таких пиков 2 из 40 (5,0%), то есть основная масса пиков — это именно обогащение ChIP над фоном, а не участки, где высоко всё подряд.




Рис. 3: Fingerprint ChIP и Input: 75ep (слева, JSD = 0,019) и 1-2ss (справа, JSD = 0,036)

4 Четыре стадии вместе

4.1 Сводные метрики

Таблица 5: Все стадии. FE — медианный fold-enrichment пиков; JSD — из plotFingerprint; дубли — redundant rate ChIP по MACS3

Стадия	ChIP	Input	Пиков	FRiP	FRiP Input	FE	JSD	Дубли
75ep	23 863 894	39 931 858	36	0,0200 %	0,0100 %	5,8	0,019	0 %
1-2ss	12 816 614	33 460 348	40	0,0100 %	0 %	6,1	0,036	0 %
5-6ss	18 853 396	н/д	839	0,236 %	н/д	5,5	н/д	0 %
14ss	41 553 880	27 794 668	170	0,160 %	0,0900 %	3,3	0,016	0 %




Рис. 4: Число пиков при полной и при одинаковой глубине, FRiP ChIP и Input, медианный FE и JSD по стадиям

Число пиков по порядку стадий: 75ep (36) → 1-2ss (40) → 5-6ss (839) → 14ss (170). FRiP: 75ep (0,0200 %) → 1-2ss (0,0100 %) → 5-6ss (0,236 %) → 14ss (0,160 %). Разброс огромный: между

крайними стадиями по числу пиков разница в 23 раза, по FRiP — в 24 раза.

Первое, что хочется проверить, — не сводится ли всё к глубине. Больше всего пиков у 5-6ss (839), хотя по глубине ChIP она только на 3-м месте из 4 (18 853 396 против 41 553 880 у 14ss). То есть число пиков явно определяется не одной глубиной. Оговорка: 5-6ss взята из готовых файлов преподавателя, и её Input и параметры обработки проверить нельзя, поэтому это сравнение не совсем честное.

Второе — качество. Отношение доли ридов ChIP в пиках к доле ридов Input в тех же пиках: 75ep: 2,0 ×; 14ss: 1,8 ×. JSD между ChIP и Input: 75ep: 0,019; 1-2ss: 0,036; 14ss: 0,016. Порядок стадий по числу пиков не совпадает с порядком по FRiP, так что число пиков нельзя целиком свести к качеству ChIP.

4.2 Сила обогащения




Рис. 5: Распределение $\log_2(\text{FE})$ в summit, значимость пиков по рангу и ширина пиков

Медианный FE, на первый взгляд, должен отвечать на вопрос «где Foxd3 связан сильнее». Но у этого числа есть ловушка отбора: FE считается только по вызванным пикам, а порог пропускает прежде всего самые сильные места. У стадии с плохим ChIP проходят считанные пики, зато очень яркие, и медианный FE у неё может выйти даже выше, чем у стадии с хорошим ChIP и тысячей пиков разной силы. Поэтому сравнивать силу обогащения по спискам пиков разного размера некорректно. Правильнее смотреть на сигнал всех стадий на одном и том же наборе регионов, это сделано в разделе 4.4.

4.3 Попарные пересечения и индекс Жаккара

```
sort -k1,1 -k2,2n peaks.narrowPeak > sorted.narrowPeak    # jaccard требует сортировку
bedtools intersect -a A -b B -u | wc -l                    # пики A, у которых есть пара в B
bedtools intersect -a B -b A -u | wc -l                    # и наоборот
bedtools jaccard -a A -b B                                # пересечение / объединение в п.н.
```

Индекс Жаккара у `bedtools` считается по нуклеотидам:

$$J(A, B) = \frac{|A \cap B|_{\text{п.н.}}}{|A \cup B|_{\text{п.н.}}}.$$

У него есть свойство, из-за которого его легко неправильно прочесть: при разных размерах наборов он ограничен сверху. Даже если меньший набор целиком лежит внутри большего, J не превысит отношения их суммарных длин $|A|/|B|$. Поэтому в таблице рядом с J стоят и доли пиков каждого набора, нашедших пару в другом.

Таблица 6: Все пары стадий. «А в В» — сколько пиков А пересекаются хотя бы с одним пиком В

A	B	пиков А	пиков В	А в В	В в А	J
75ep	1-2ss	36	40	12 (33 %)	12 (30 %)	0,174
75ep	5-6ss	36	839	22 (61 %)	22 (2,6 %)	0,023
75ep	14ss	36	170	18 (50 %)	18 (11 %)	0,075
1-2ss	5-6ss	40	839	30 (75 %)	30 (3,6 %)	0,028
1-2ss	14ss	40	170	12 (30 %)	12 (7,1 %)	0,043
5-6ss	14ss	839	170	40 (4,8 %)	40 (24 %)	0,037




Рис. 6: Индекс Жаккара (слева) и доля пиков стадии-строки, перекрытых пиками стадии-столбца (справа)

По Жаккару ближе всего **75ep и 1-2ss** ($J = 0,174$), дальше всего **75ep и 5-6ss** ($J = 0,023$). Но по долям картина другая: например, **75 %** пиков **1-2ss** лежат внутри пиков **5-6ss**, а J для этой пары всего **0,028**. То есть низкий J здесь в основном отражает разницу в размерах наборов, а не то, что сайты стадий не совпадают.

4.4 Общие и специфичные регионы

Чтобы смотреть на все стадии сразу, пики всех стадий сливаются в один набор регионов, и для каждого региона отмечается, на каких стадиях он найден:

```
for s in 75ep 1-2ss 5-6ss 14ss; do          # 4-я колонка = имя стадии
    awk -v s=$s 'BEGIN{OFS="\t"} {print $1,$2,$3,s,$9,$7}' foxd3_$.sorted.narrowPeak
done | sort -k1,1 -k2,2n \
    | bedtools merge -i - -c 4,4,5,6 -o count_distinct,distinct,max,max
```

Всего получается **982** регионов. На всех **4** стадиях найдено **6**, только на одной — **905 (92 %)**. Пиков, которые не пересекаются ни с одной другой стадией: **75ep** — **6** из **36**; **1-2ss** — **7** из **40**; **5-6ss** — **773** из **839**; **14ss** — **119** из **170**.

Таблица 7: Самые частые сочетания стадий, в которых найден регион

Стадии	число стадий	регионов
5-6ss	1	773
14ss	1	119
5-6ss+14ss	2	26
1-2ss+5-6ss	2	15
75ep+14ss	2	8
1-2ss	1	7
75ep	1	6
75ep+1-2ss+5-6ss	3	6
75ep+1-2ss+5-6ss+14ss	4	6
75ep+5-6ss	2	5

Здесь важно не перепутать слова. «Специфичный для стадии» в этой таблице значит только одно: на других стадиях пик не вызван. Это не то же самое, что «на других стадиях Foxd3 там не сидит», потому что на стадиях с плохим ChIP не вызвано вообще почти ничего. Отличить эти два случая можно только по самому сигналу, для этого следующий шаг.




Рис. 7: Слева: корреляция Спирмена $\log_2(\text{ChIP}/\text{Input})$ между стадиями на union-регионах. Справа: сигнал всех стадий на union-регионах, разбитых k-means на 5 кластеров

```
multiBigwigSummary BED-file -b *.log2_IP_Input.bw --BED union_peaks.bed -o log2.npz
plotCorrelation -in log2.npz --corMethod spearman --whatToPlot heatmap
computeMatrix reference-point --referencePoint center -R union_peaks.bed \
-S *.log2_IP_Input.bw -b 1000 -a 1000 --missingDataAsZero -o union.matrix.gz
plotHeatmap -m union.matrix.gz --kmeans 5
```

Корреляция Спирмена выбрана потому, что сигнал на пиках очень асимметричный, и Пирсон держался бы на нескольких самых ярких точках. Сильнее всего коррелируют 1-2ss и 5-6ss ($\rho = 0,55$), слабее всего 1-2ss и 14ss ($\rho = -0,03$).

На heatmap каждая строка — регион, и видно, на каких стадиях в нём есть сигнал, даже если пик там не вызван.

4.5 Положение относительно TSS




Рис. 8: Расстояние от summit до ближайшего TSS: распределение в ± 10 kb (слева) и доли по интервалам расстояний (справа)

Доля summit в пределах 1 kb от TSS: 75ep: 11 %; 1-2ss: 18 %; 5-6ss: 37 %; 14ss: 16 %. Доля промоторных пиков заметно различается между стадиями, это стоит держать в голове при сравнении: наборы пиков разного состава. Там, где пиков всего несколько десятков, эти доли посчитаны по паре десятков точек, и один-два пика сдвигают их на несколько процентов, так что сравнивать их между собой надо осторожно.

4.6 Одинаковая глубина

Самая прямая проверка того, объясняются ли различия глубиной: уменьшить все библиотеки до одного размера и вызвать пики заново. `samtools view -s` выбирает ряды по хэшу имени, поэтому оба ряда пары либо остаются, либо уходят вместе, и BAMPE-режим MACS3 не ломается.

```
# доля = (самая мелкая ChIP-библиотека) / (эта библиотека); 42 --- seed
samtools view -b -s 42.$\frac{}{} -o chip.ds.bam chip.bam      # так же и Input
macs3 callpeak -t chip.ds.bam -c input.ds.bam -f BAMPE -g 13600000000 -q 0.01 ...
```

Все ChIP урезаются до 12 816 614 записей (самая мелкая из библиотек, для которых есть BAM: 75ep, 1-2ss, 14ss), все Input — до самого мелкого Input.

Таблица 8: Число пиков до и после выравнивания глубины

Стадия	ChIP, записей	пиков	пиков после	осталось
75ep	23 863 894	36	17	47 %
1-2ss	12 816 614	40	39	98 %
14ss	41 553 880	170	45	26 %

После выравнивания глубины порядок стадий по числу пиков не меняется (75ep: 36 → 17; 1-2ss: 40 → 39; 14ss: 170 → 45). Значит, различия между этими стадиями нельзя списать на то, что какую-то библиотеку просто глубже отсековенировали. Сильнее всего урезается 14ss: от неё остаётся 31 % рядов, и число пиков падает до 26 % исходного.

5 IGV

Для ChIP-треков включён общий масштаб (Group Autoscale), чтобы высоту можно было сравнивать между стадиями. Локусы выбраны автоматически по результатам: самый значимый пик 5-6ss, самый сильный регион, общий для наибольшего числа стадий, и самый сильный регион, найденный только на одной стадии.

Про общий масштаб есть оговорка. Высота пика в CPM зависит не только от связывания, но и от эффективности ChIP: чем больше FRiP, тем большая доля библиотеки уходит в пики и тем они выше при той же нормировке. Поэтому если пик на одной стадии выше, чем на другой, это ещё не значит, что Foxd3 там связан сильнее. Надёжнее сравнивать высоту пика с другими пиками той же стадии.

5.1 Локус 1: самый сильный пик

Окно NC_007117.7:32201757-32211757 (NC_007117.7 (хр. 6), 10,0 kb): самый значимый peak 5-6ss: foxd3_5-6ss_chip_peak_211, FE=21.1014, $-\log_{10} q=163.701$. Ближайший ген: *LOC137495883* (в 59 kb от центра окна).




Рис. 9: Локус 1: самый значимый пик 5-6ss, окно NC_007117.7:32201757-32211757

Пик ChIP стоит точно под вызванным интервалом narrowPeak, а Input в этом месте ровный

5.2 Локус 2: регион, общий для нескольких стадий

Окно NC_007113.7:33271304-33281304 (NC_007113.7 (хр. 2)): регион найден на 4 стадиях (75ep+1-2ss+5-6ss+14ss). Ближайший ген: *klf17* (в 50 kb от центра окна).




Рис. 10: Локус 2: регион, связанный на нескольких стадиях, окно NC_007113.7:33271304-33281304

Честно говоря тут только маленькие пички видны, но они сильные и стабильные.

5.3 Локус 3: регион, найденный только на одной стадии

Окно NW_003336809.1:1-6585 (NW_003336809.1): найден только на 14ss, $-\log_{10} q=148.07$, FE=2.99794. Ближайший ген: *LOC137489780* (в 3,9 kb от центра окна).




Рис. 11: Локус 3: регион, найденный только на 14ss, окно NW_003336809.1:1-6585

Главный вопрос к этому локусу — на других стадиях сигнала нет совсем или он есть, но не прошёл порог. На других стадиях виден слабый подъём, не дотянувший до порога MACS3, и тогда «специфичность» — скорее вопрос чувствительности эксперимента, чем биологии.

5.4 Бонус, локус 4: окрестности самого foxd3

Окно NC_007117.7:32032031-32153830: сам ген foxd3 и ± 60 kb вокруг, то есть тот участок, который показан на рис. 3С в статью с энхансерами enh6 и enh8.




Рис. 12: Локус 4: ген foxd3 и его окрестности, окно NC_007117.7:32032031-32153830

6 Форматы файлов

GTF. Текстовая аннотация генов, девять колонок через табуляцию: хромосома, источник, тип элемента (gene, transcript, exon, CDS...), начало, конец, score, цепь, рамка считывания и атрибуты. Координаты считаются с единицы, и конец входит в интервал. Иерархия ген → транскрипт → экзон задаётся атрибутами. Схематичный пример (координаты условные):

```
| NC_007112.7 RefSeq exon 10001 10350 . + . gene_id "g1"; transcript_id "t1";
```

GTF нужен, чтобы в IGV были видны гены, и чтобы привязывать пики к генам. В reference/курса вместо него лежит упрощённый genes.bed: одна строка на ген, BED-координаты.

BigWig. Бинарный формат для непрерывного сигнала вдоль генома: для каждого интервала хранится одно число. Внутри есть индекс и заранее посчитанные сводки на нескольких масштабах, поэтому IGV открывает трек на весь геном мгновенно и читает только видимый кусок. Отдельных рядов в BigWig нет, и обратно в BAM его не превратить. У нас это CPM-треки ChIP и Input (бин 10 п.н.) и log2(ChIP/Input).

BED. Текстовый формат интервалов. Обязательны три колонки — хромосома, начало, конец, — дальше по желанию имя, score, цепь и т. д. до двенадцати. Координаты с нуля, конец не включается, поэтому длина интервала просто end — start, а одна позиция записывается как [s, s + 1). Так выглядит summit самого значимого пика 14ss:

```
NC_007126.7 35583736 35583737 foxd3_14ss_peak_74 321.453
```

narrowPeak. BED6+4 от MACS3: шесть колонок BED (strand всегда «.») и ещё четыре: fold-enrichment в summit, $-\log_{10} p$, $-\log_{10} q$ и смещение summit от начала пика. Подробный разбор колонок — в отчёте по семинару. Строка того же пика:

```
NC_007126.7 35583506 35583991 foxd3_14ss_peak_74 3214 . 24.9995 330.35 321.453 230
```

peaks.xls. Несмотря на расширение, это не Excel, а текстовая таблица через табуляцию. Сначала идёт шапка из строк с #: все параметры запуска, число фрагментов до и после удаления дубликатов, доля дубликатов (**Redundant rate**), длина фрагмента (# d = y 14ss 205). Потом таблица пиков: chr, start, end, length, abs_summit, pileup, $-\log_{10}(\text{pvalue})$, fold_enrichment, $-\log_{10}(\text{qvalue})$, name. Важная мелочь: здесь start считается с единицы, а в narrowPeak с нуля, так что у одного и того же пика start в двух файлах различается на 1.

matrix.gz. Результат computeMatrix, сжатый текст. Первая строка начинается с @ и содержит JSON с параметрами (размеры окна, бин, границы образцов). Дальше по строке на регион: шесть колонок BED и значения сигнала по бинам для всех треков подряд. У 14ss это 170 строк по 406 колонок. Из этой матрицы plotHeatmap и plotProfile рисуют картинки, и из неё же в этом отчёте посчитаны отношения центра к краям.

7 Ответ на итоговый вопрос

Как меняется ландшафт. По числу пиков 75ep (36) → 1-2ss (40) → 5-6ss (839) → 14ss (170), по FRiP 75ep (0,0200 %) → 1-2ss (0,0100 %) → 5-6ss (0,236 %) → 14ss (0,160 %). Из 982 union-регионов 6 найдены на всех стадиях, а 92 % — только на одной. Если читать число пиков буквально, получается так: 75ep → 1-2ss почти без изменений (36 → 40); 1-2ss → 5-6ss рост в 21 раз (40 → 839); 5-6ss → 14ss падение в 4,9 раза (839 → 170). Вопрос в том, сколько в этом буквальном прочтении правды.

Что можно считать биологией с достаточной уверенностью.

- Существование общего ядра регионов, связанных на всех стадиях (6 регионов, пример — локус 2). Эти пики вызываются в экспериментах очень разного качества, и объяснить их артефактом одной библиотеки трудно.
- Различия, которые переживают выравнивание глубины. После выравнивания глубины порядок стадий по числу пиков не меняется (75ep: 36 → 17; 1-2ss: 40 → 39; 14ss: 170 → 45). Значит, различия между этими стадиями нельзя списать на то, что какую-то библиотеку просто глубже отсековировали. Сильнее всего урезается 14ss: от неё остаётся 31 % ридов, и число пиков падает до 26 % исходного.
- Регионы, где на одной стадии сильный пик, а на другой стадии с нормальным ChIP сигнала нет совсем, а не просто нет вызванного пика (проверяется по k-means heatmap и по локусу 3).

Что нельзя отделить от качества эксперимента.

- Абсолютное число пиков и FRiP. Отношение ChIP к Input в пиках и JSD различаются между стадиями, то есть сами эксперименты разного качества; хуже всего сигнал отделяется от фона у 14ss (1,8 ×). Порядок стадий по числу пиков не совпадает с порядком по FRiP, так что число пиков нельзя целиком свести к качеству ChIP.
- Всё, что касается 5-6ss: эта стадия обработана не в том же пайплайне, её Input и параметры MACS3 неизвестны, а fingerprint и даунсэмплинг для неё не посчитать.

- Любые количественные различия в силе связывания: на стадию по одному повтору, поэтому разброс внутри стадии неизвестен и формально проверить дифференциальное связывание (например, DiffBind или csaw) нельзя.

Что нужно, чтобы ответить строже. Биологические повторы на каждую стадию; одинаковая обработка всех стадий, включая 5-6ss; пики на BirA-only контроле, чтобы исключить то, что стрептавидин тащит неспецифически; и сравнение сигнала на общем наборе регионов со статистикой по повторам. А чтобы перейти от связывания к регуляции, нужны данные из той же статьи: ATAC-seq (меняется ли доступность хроматина под пиком при потере Foxd3), H3K27ac (активен ли элемент) и RNA-seq (меняется ли экспрессия генов рядом).

Итог. Ландшафт связывания Foxd3 от гаструляции к миграции действительно меняется: есть устойчивое ядро сайтов, связанных на всех стадиях, и много регионов, специфичных для отдельных стадий. **Размеры наборов пиков целиком к качеству ChIP не сводятся, но без повторов и одинаковой обработки всех стадий утверждение «на стадии X Foxd3 связывает больше сайтов» всё равно остаётся ненадёжным.** Уверенно можно говорить о конкретных локусах: об общем ядре и о тех регионах, где разница между стадиями видна по сигналу, а не только по тому, прошёл пик порог или нет.