

Семинар 2. ChIP-seq Foxd3 у *Danio rerio*

стадия 14 somite stage (14ss)

Коротков Антон

27 сентября

1 О чём работа

Foxd3 — транскрипционный фактор семейства forkhead, без которого не формируется нормальный нервный гребень. Семинар построен на статье Lukoseviciute et al, где показано, что у Foxd3 две фазы работы. Сначала он ведёт себя как пионер-фактор: садится на ещё закрытый хроматин и помогает открыть энхансеры программы нервного гребня. Позже он становится в основном репрессором и придерживает гены миграции и дифференцировки, пока клетки к этому не готовы.

Карты связывания в статье получены не обычным ChIP с антителом, а bioChIP-seq. На Foxd3 навешен короткий AviTag, биотин-лигаза BirA прямо в эмбрионе присоединяет к нему биотин, а после сшивки и фрагментации хроматина белок вместе с ДНК вытаскивают стрептавидином. Контроль самой системы — эмбрионы, где есть только BirA, а контроль фона хроматина — обычный Input.

Задача семинара — пройти весь путь от готовых BAM до пиков и оценки качества для одной стадии, 14ss (клетки нервного гребня в это время уже мигрируют), и сопоставить результат с разобранной (ground truth from teacher) стадией 5–6ss.

2 Данные и запуск

На входе два BAM, уже выровненных на GRCz11 и отфильтрованных: `foxd3_14ss_chip.nuclear.bam` (Foxd3 bioChIP) и `foxd3_14ss_input.nuclear.bam` (Input), плюс из `reference/` геном и аннотация (`genes.bed`, `tss.bed`). Слово `nuclear` в имени означает, что оставлены только ядерные хромосомы, и это подтверждается `samtools idxstats`: на митохондриальный контиг в ChIP приходится 0 ридов, ненулевое покрытие есть на 1899 контигах из 1923.

Хромосомы в сборке названы по RefSeq, поэтому рядом с именами вида `NC_0071xx.7` я в скобках пишу номер хромосомы: `NC_007112.7` это хромосома 1, дальше по порядку до `NC_007136.7` (хромосома 25).

3 Контроль качества BAM

```
samtools flagstat data/foxd3_14ss_chip.nuclear.bam
samtools flagstat data/foxd3_14ss_input.nuclear.bam
```

Таблица 1: samtools flagstat, стадия 14ss

	ChIP	Input
Всего записей (alignments)	41 553 880	27 794 668
Пар (read1)	20 776 940	13 897 334
Картировано	100,00 %	100,00 %
Properly paired	100,00 %	100,00 %
Secondary / supplementary	0 / 0	0 / 0
Singletons	0	0
Помечено дубликатов (флаг 0x400)	0	0

Для сырого выравнивания такая таблица слишком чистая: всё картировано, все пары правильные, нет ни singletons, ни вторичных, ни supplementary записей. Значит, BAM уже прошли фильтрацию и в них оставлены только нормально спаренные выравнивания. Раз secondary и supplementary нет, число записей равно числу ридов, а пар ровно вдвое меньше.

Ноль в строке duplicates не означает, что дубликатов нет. **flagstat** считает только записи с выставленным флагом 0x400, а **markdup**/Picard по этим файлам, судя по всему, не запускали. Реальную долю дубликатов видно позже: MACS3 по умолчанию (**--keep-dup 1**) оставляет один фрагмент на каждую пару координат и пишет долю выброшенного в шапку **peaks.xls**. У ChIP это 0 %, у Input 0 %.

Глубина у библиотек разная: отношение числа ридов ChIP к Input равно 1,50. Сравнивать их напрямую по сырым счётам нельзя, поэтому треки нормированы на CPM, а MACS3 сам приводит большую библиотеку к масштабу меньшей (**--scale-to small** по умолчанию).

4 Сигнальные дорожки

```
bamCoverage -b data/foxd3_14ss_chip.nuclear.bam \
-o results/signal/foxd3_14ss_chip.CPM.bw \
--normalizeUsing CPM --binSize 10 --numberOfProcessors 8
# то же для Input → results/signal/foxd3_14ss_input.CPM.bw
bigwigCompare -b1 results/signal/foxd3_14ss_chip.CPM.bw \
-b2 results/signal/foxd3_14ss_input.CPM.bw \
--operation log2 --pseudocount 1 --binSize 10 \
-o results/signal/foxd3_14ss.log2_IP_Input.bw
```

bamCoverage режет геном на бины по 10 п.н. и в каждом считает

$$\text{CPM}(b) = \frac{N_b}{N_{\text{total}}/10^6},$$

где N_b — число ридов, перекрывающих бин. Нормировка на миллион ридов нужна, чтобы треки разной глубины можно было класть рядом. 10 п.н. — разумный компромисс: форма отдельного пика в IGV видна, а файл не раздувается, как было бы с бином в 1 п.н.

Тут же вспоминается слайд «Read $\neq$ fragment»: без **--extendReads** **bamCoverage** считает именно риды, а не фрагменты. У парных данных каждый фрагмент даёт два риды по своим краям, так что середина фрагмента в таком покрытии недопредставлена. Для картинок это некритично, а статистику считает MACS3, который с **-f BAMPE** работает уже с целыми фрагментами.

Дорожка обогащения:

$$S(b) = \log_2 \frac{\text{CPM}_{\text{ChIP}}(b) + 1}{\text{CPM}_{\text{Input}}(b) + 1}.$$

Про псевдосчёт есть тонкость. Единица прибавляется к CPM, а не к числу ридов, а при глубине ChIP 41 553 880 один CPM — это примерно 42 ридов в бине. То есть +1 в числителе

и знаменателе равносильно добавлению нескольких десятков ридов, и все отношения сильно прижимаются к нулю: в хорошем пике S обычно порядка единицы, хотя настоящее обогащение там в разы больше. Поэтому $\log_2$ -трек я использую только как инструмент для глаз (где ChIP выше Input), а количественно силу обогащения беру из fold-enrichment'a, который считает MACS3.

5 Поиск пиков: MACS3

```
macs3 callpeak -t data/foxd3_14ss_chip.nuclear.bam \
  -c data/foxd3_14ss_input.nuclear.bam \
  -f BAMPE -g 13600000000 -n foxd3_14ss -q 0.01 \
  --outdir results/peaks
```

Параметры:

- **-f BAMPE**: фрагменты известны точно по парам ридов, и MACS3 не нужно строить модель сдвига, как для single-end. Среднюю длину фрагмента он при этом всё равно сообщает: $d = 205$ п.н.
- **-g 13600000000**: эффективный размер генома, то есть та его часть, куда риды вообще могут однозначно картироваться. От него зависит самый грубый фон λ_{genome} .
- **-q 0.01**: порог по FDR, об этом ниже.

В каждой позиции MACS3 сравнивает наблюдаемое число фрагментов ChIP k с ожидаемым фоном, который оценивается по Input сразу на нескольких масштабах:

$$\lambda_{\text{local}} = \max(\lambda_{\text{genome}}, \lambda_d, \lambda_{1\text{kb}}, \lambda_{10\text{kb}}), \quad p = P(K \geq k), \quad K \sim \text{Poisson}(\lambda_{\text{local}}).$$

Максимум здесь — осторожный выбор: если вокруг позиции Input и так высокий, ChIP сравнивается с ним, а не с заниженным средним по геному. Потом p-value пересчитываются в q-value по Бенджамини–Хокбергу, $q_{(i)} = \min_{j \geq i} \frac{m}{j} p_{(j)}$, и соседние позиции с $q < 0,01$ склеиваются в пики.

Найдено 170 пиков. Медианная ширина 310 п.н. (от 205 до 1965), то есть порядок длины фрагмента, как и положено узким пикам транскрипционного фактора. Вместе все пики занимают 66,2 kb, это 0,0049 % эффективного генома.

Число пиков и число сайтов связывания — не одно и то же. Причин несколько. Во-первых, число пиков — функция порога: при $q < 0,05$ их было бы больше, при $q < 0,001$ меньше, а сами сайты от этого не меняются. Во-вторых, оно зависит от глубины и качества эксперимента: слабый, но настоящий сайт при этой глубине может просто не набрать значимости. В-третьих, пик и сайт не соотносятся один к одному: два мотива на расстоянии меньше длины фрагмента дадут один пик. В-четвёртых, FDR 1 % контролирует только статистический шум внутри пуассоновской модели, то есть в среднем ложных среди них порядка 1,7. Систематические артефакты (места, где высок и Input) он не ловит, про них в разделе 9. И наконец, ChIP видит и не прямое связывание, когда Foxd3 держится за ДНК через белок-партнёра.

Формат narrowPeak. Это BED6+4: шесть обычных колонок BED и четыре со статистикой. Вот строка самого значимого пика целиком:

```
NC_007126.7 35583506 35583991 foxd3_14ss_peak_74 3214 . 24.9995 330.35 321.453 230
```

Таблица 2: Колонки `narrowPeak` на примере самого значимого пика 14ss

№	Поле	Значение	Смысл
1–3	chrom, start, end	NC_007126.7:35 583 506-35 583 991	координаты пика; как во всём BED, start с нуля, end не включается
4	name	foxd3_14ss_peak_74	идентификатор
5	score	3 214	у MACS3 это $\lfloor 10 \cdot (-\log_{10} q) \rfloor$; на наших данных это выполняется для всех пиков (170 из 170). Браузеры используют его для яркости
6	strand	.	у ChIP-пика нет цепи
7	signalValue	25,00	fold-enrichment в summit относительно λ_{local}
8	pValue	330,35	$-\log_{10} p$
9	qValue	321,45	$-\log_{10} q$
10	peak	230	смещение summit от start; абсолютная координата = start + peak

6 Самые значимые пики

```
| sort -k9,9gr results/peaks/foxd3_14ss_peaks.narrowPeak | head
```

Сортировка по девятой колонке, $-\log_{10} q$, по убыванию. Ключ `g` вместо `n` понимает экспоненциальную запись вроде `1e+03`. MACS3 её обычно не пишет, но так надёжнее.

Таблица 3: Пять самых значимых пиков 14ss. Ближайший ген — из `reference/genes.bed` по расстоянию от summit до границ гена (0 — summit внутри гена); это ориентир, а не утверждение, что пик регулирует именно этот ген

Пик	Координаты	FE	$-\log_{10} q$	Ближайший ген
foxd3_14ss_peak_74	NC_007126.7:35583506–35583991	25,0	321,5	<i>mecom</i>
foxd3_14ss_peak_9	NC_007114.7:14914162–14914708	34,7	280,5	<i>nfixb</i>
foxd3_14ss_peak_4	NC_007112.7:52006311–52006785	17,9	152,4	<i>nfixa</i>
foxd3_14ss_peak_149	NW_003336809.1:1264–1906	3,0	148,1	<i>LOC137489780</i> (5,7 kb)
foxd3_14ss_peak_148	NW_003336809.1:684–949	3,3	115,2	<i>LOC137489780</i> (6,3 kb)

Самый значимый пик — `foxd3_14ss_peak_74` на NC_007126.7 (xp. 15), fold-enrichment 25,00, $-\log_{10} p = 330,35$, $-\log_{10} q = 321,45$. Отсюда

$$q = 10^{-321,45} \approx 3,5 \cdot 10^{-322}.$$

MACS3 хранит логарифм, а не сам q , и это не просто удобство: наименьшее нормальное число двойной точности порядка 10^{-308} , и у самых сильных пиков q легко уходит за этот предел, то есть в обычном float его уже не записать.

Самый значимый пик и пик с максимальным fold-enrichment здесь не совпадают: максимальный FE = 34,67 у `foxd3_14ss_peak_9`, но у него $-\log_{10} q = 280,49$ против 321,45 у лидера. Это нормально: q -value зависит не только от отношения ChIP к фону, но и от того, сколько там вообще фрагментов. Если локальный фон λ маленький, то даже десятикратное превышение набирается из пары десятков фрагментов и пуассоновский хвост получается не таким уж экстремальным.

7 FRiP

```
| samtools view -c data/foxd3_14ss_chip.nuclear.bam
| samtools view -c -L results/peaks/foxd3_14ss_peaks.narrowPeak \
| data/foxd3_14ss_chip.nuclear.bam
```

Первая команда даёт знаменатель, вторая — число записей, перекрывающих хотя бы один пик (-L ограничивает выдачу интервалами из файла):

$$\text{FRiP} = \frac{N_{\text{в пиках}}}{N_{\text{всего}}} = \frac{67\,346}{41\,553\,880} \approx 0,160\%.$$

Сам по себе FRiP трудно оценить, поэтому скрипт считает то же самое для Input в тех же координатах: 25 186 ридов, то есть 0,0900 %. Столько попало бы в пики вообще без иммуно-преципитации, просто из-за фона. ChIP в пиках обогащён относительно Input в 1,8 ×.

Для ChIP-seq транскрипционных факторов в рекомендациях ENCODE ориентир — FRiP порядка 1 % и выше, наш в 6,2 раза ниже. Но на это есть понятные причины. Пиков мало, и они узкие: все вместе занимают 0,0049 % генома, а собирают 0,160 % ридов, то есть плотность ридов в пиках примерно в 33 раза выше средней по геному. Кроме того, bioChIP, насколько я понимаю схему эксперимента, делается на целых эмбрионах (FACS в статье нужен для RNA-seq, ATAC и H3K27ac), а Foxd3-Avi есть только в foxd3⁺ клетках, которых среди всех клеток эмбриона меньшинство. Большая часть хроматина в образце Foxd3 просто не содержит, и сигнал разбавлен.

8 Отпечаток библиотеки: plotFingerprint

FRiP завязан на то, какие пики вызваны. Хочется ещё метрику, которая от peak calling не зависит, и её даёт plotFingerprint

```
plotFingerprint -b chip.bam input.bam --labels 14ss_ChIP 14ss_Input \
  --extendReads --skipZeros --numberOfSamples 500000 \
  --JSDsample input.bam --outQualityMetrics foxd3_14ss.fingerprint_metrics.tsv \
  --plotFile foxd3_14ss.fingerprint.pdf
```

Он берёт полмиллиона случайных бинов по 500 п.н., сортирует их по покрытию и рисует накопленную долю ридов. У Input кривая близка к диагонали (риды распределены равномерно), а у ChIP с сильным обогащением она долго лежит внизу и резко взлетает в самом конце, потому что много ридов сосредоточено в немногих бинах. Численно разницу между ChIP и Input выражает расстояние Дженсена–Шеннона: JSD = 0,016 (для сравнения с идеальным пуассоновским фоном — 0,310). Универсального порога для JSD нет, поэтому в ДЗ эта метрика используется для сравнения стадий между собой.




Рис. 1: Fingerprint для ChIP и Input, 14ss

9 Сигнал вокруг summit

```
computeMatrix reference-point --referencePoint center \  
-R results/peaks/foxd3_14ss_summits.bed \  
-S results/signal/foxd3_14ss_chip.CPM.bw results/signal/foxd3_14ss_input.CPM.bw \  
-b 2000 -a 2000 --binSize 20 -o results/figures/foxd3_14ss.matrix.gz  
plotHeatmap -m results/figures/foxd3_14ss.matrix.gz \  
-out results/figures/foxd3_14ss.heatmap.pdf \  
--samplesLabel "Foxd3 ChIP" "Input" --refPointLabel "summit"  
plotProfile -m results/figures/foxd3_14ss.matrix.gz \  
-out results/figures/foxd3_14ss.profile.pdf \  
--samplesLabel "Foxd3 ChIP" "Input" --refPointLabel "summit"
```

`matrix.gz` — обычная сжатая текстовая таблица. Первая строка начинается с @ и содержит JSON с параметрами. Далее 170 строк, по одной на пик: шесть колонок BED и значения CPM по бинам, 200 бинов на трек (окно 4 kb / 20 п.н.) и два трека подряд, всего 406 колонок. Heatmap рисует эту таблицу построчно, profile усредняет её по пикам.




Рис. 2: Средний сигнал ChIP и Input в окне ± 2 kb вокруг summit, 14ss




Рис. 3: Сигнал по каждому из 170 пиков 14ss

Чтобы не описывать картинку на глаз, по той же матрице посчитано, во сколько раз средний сигнал в центре окна (± 200 п.н. от summit) выше, чем на краях (крайние 500 п.н. с каждой стороны): у ChIP $2,7 \times$, у Input $2,4 \times$. У Input в центре тоже есть подъём. Это не обязательно плохо: фон в местах связывания часто чуть выше среднего, потому что открытый хроматин лучше фрагментируется. Но если подъём Input сравним с ChIP, пик уже подозрителен, и это имеет смысл посчитать по отдельным пикам.

Среднее, впрочем, может скрыть неприятные пики, поэтому дальше посчитано, у скольких пиков Input в центре окна не меньше половины ChIP. Таких пиков 96 из 170 (56%), это заметная доля. В этих местах фон и так высокий, и повышенное покрытие там может быть не связыванием Foxd3, а свойством самого участка: повторы, схлопнутые при сборке копии, сильно открытый хроматин, который лучше фрагментируется. На heatmap они как раз собираются в верхних строках, где Input тоже яркий.

10 Где пики относительно генов

Для каждого summit находится ближайший TSS из `tss.bed` (`bedtools closest -D b`, знак расстояния с учётом цепи гена, минус — выше по течению). В пределах 1 kb от TSS лежит

16 % summit, дальше 10 kb — 59 %, медианное расстояние 18 kb. Большая часть пиков лежит вдали от промоторов, то есть Foxd3 на этой стадии связывается в основном с дистальными элементами, скорее всего энхансерами. Это согласуется со статьёй, где ключевые мишени Foxd3 — именно энхансеры генов нервного гребня. Но близость к гену не доказывает, что пик регулирует именно его: энхансер может работать на ген за десятки килобаз.

11 Сопоставление с 5–6ss

```
bedtools intersect -a teacher/5-6ss/peaks/foxd3_5-6ss_chip_peaks.narrowPeak \
  -b results/peaks/foxd3_14ss_peaks.narrowPeak -u \
  > results/stage_comparison/shared_5-6ss_14ss.bed
bedtools intersect -a results/peaks/foxd3_14ss_peaks.narrowPeak \
  -b teacher/5-6ss/peaks/foxd3_5-6ss_chip_peaks.narrowPeak -v \
  > results/stage_comparison/only_14ss.bed
```

Пересечением `bedtools` считает хотя бы один общий нуклеотид. `-u` выводит интервал из А один раз, если у него есть хоть одно пересечение с В; без этого флага пик А, задетый двумя пиками В, попал бы в выдачу дважды. `-v` делает обратное и оставляет интервалы А без единого пересечения.

Таблица 4: 5–6ss и 14ss

	5–6ss	14ss
Откуда	готовые файлы преподавателя	посчитано в пайплайне
ChIP alignments	18 853 396	41 553 880
Пиков	839	170
FRiP	0,236 %	0,160 %
Пересекаются с другой стадией	40 (4,8 %)	40 (24 %)
Только на этой стадии	799	130 (76 %)

Перекрытие получается несимметричным, и это стоит проговорить. Из пиков 5–6ss пару на 14ss находят 40, это 4,8 % от 5–6ss, а со стороны 14ss общими оказываются 40 пиков, то есть 24 %. Дело просто в разном размере наборов: большой набор может накрыть заметную долю маленького, а наоборот — нет. Поэтому «доля общих пиков» без уточнения, от какого набора она считается, ничего не значит.

Библиотека 5–6ss мельче (18 853 396 против 41 553 880 alignments), а пиков в ней в 4,9 раза больше, так что разницу в числе пиков глубиной объяснить нельзя: если бы дело было в глубине, всё было бы наоборот. Но FRiP у 5–6ss 0,236 %, у 14ss 0,160 %, то есть это ещё и эксперименты разного качества, а разное качество ChIP даёт разное число пиков ничуть не хуже биологии.

Итого на этой паре стадий честно можно сказать следующее: набор пиков между 5–6ss и 14ss сильно меняется, но есть общее ядро участков, связанных на обеих стадиях. Какая часть изменений — биология, а какая — разница в качестве двух экспериментов, из одного такого сравнения не понять. Для этого нужны метрики качества по всем стадиям и контроль глубины, и это сделано в ДЗ.

12 Итоги

1. Оба ВАР отфильтрованы и чистые; дубликаты не помечены, но MACS3 оценивает их долю сам (0 % у ChIP).
2. MACS3 при $q < 0,01$ находит 170 узких пиков (медиана 310 п.н.); самый значимый — `foxd3_14ss_peak_74`, $q \approx 3,5 \cdot 10^{-322}$.

3. FRiP = 0,160 % при 0,0900 % у Input в тех же местах, то есть ChIP в пиках обогащён в 1,8 $\times$. Абсолютное значение низкое, и это ожидаемо для небольшого числа узких пиков и разбавленного сигнала целого эмбриона.
4. На профиле ChIP даёт пик точно в summit: отношение центра окна к краям у ChIP 2,7 $\times$, у Input 2,4 $\times$. Пиков, где Input в центре не меньше половины ChIP, — 96 из 170.
5. С 5–6ss общими оказываются 40 пиков из 839, а 76 % пиков 14ss уникальны. Набор пиков меняется, но отделить здесь биологию от качества эксперимента по одной паре стадий нельзя.